

[Sampling Theory] 표본과 분포 — 실습 리포트

AI 서비스를 위한 SW 기초 Full-stack Engineering — 스마트 데이터 이해 및 활용 | 2026-07-27

4기 광주 4반 공동 작업 — 고윤진 · 박영서 · 안성민 · 허진녕 · 황민채

주제 1 · 제곱근의 법칙

1) 질문. 표본 크기를 4배로 늘리면 표준오차는 절반으로 줄어드는가?

→ 그렇다. 표준오차 $SE = \sigma/\sqrt{n}$ 에서 n 이 4배면 $\sqrt{4}=2$ 로 나뉘어 절반이 된다.

2) 예상.


→ n 을 4배로 늘리면 SE 가 정확히 절반이 되고, 그래프는 급락 후 완만해지는 수확 체감 곡선일 것이다.

3) 코드.

```
for n in [10, 40, 100, 400, 1000]:
    means = [np.random.normal(50, 10, size=n).mean() for _ in range(2000)]
    empirical_se = np.std(means, ddof=1)
    theoretical_se = 10 / np.sqrt(n)
```

4) 결과.

→ 경험적 SE 와 이론값($\sigma/\sqrt{n}$)이 거의 일치했고, $n=10 \rightarrow 40$ 에서 $3.14 \rightarrow 1.61$ (0.51배), $n=100 \rightarrow 400$ 에서 $0.99 \rightarrow 0.50$ (0.51배)으로 절반이 됐다.



5) 해석. 표본이 4배가 되면 표준오차는? 오차를 1/3로 줄이려면 표본은 몇 배?

→ 4배 → 표준오차 1/2. 오차를 1/3로 줄이려면 표본 9배가 필요하다($1/c$ 로 줄이려면 c^2 배). 분모가 $\sqrt{n}$ 이라 데이터를 늘릴수록 효율이 떨어지는 수확 체감이 나타난다.

6) AI 응용. AI 모델 평가의 오차를 줄이려면 데이터가 얼마나 필요한가?

→ 평가지표도 $SE \propto 1/\sqrt{n}$ 을 따른다. '많을수록'이 아니라 목표 정밀도에서 역산하는 것이 맞다 — 정확도 1%p 차이를 논하려면 테스트셋이 최소 3,000개 이상이어야 한다. 데이터를 못 늘릴 땐 paired 비교·총화추출로 분자 σ 를 줄이는 편이 효율적이다.

주제 2 · 중심극한정리 (Central Limit Theorem)

1) 질문. 원자료가 치우친 분포여도 표본평균의 분포는 정규분포에 가까워지는가?

→ 그렇다. 원자료가 치우쳐 있어도 표본평균의 분포는 n 이 커질수록 정규분포에 가까워진다.

2) 예상.


→ 지수분포(왜도 2.0)를 원자료로 쓰면, n 이 커질수록 ① 모양이 대칭 종모양이 되고 ② 퍼짐이 $1/\sqrt{n}$ 로 좁아지며, 중심은 항상 모평균 2에 머물 것이다.

3) 코드.

```
for n in [1, 5, 30, 100]:
    means = [np.random.exponential(scale=2, size=n).mean() for _ in range(5000)]
    plt.hist(means, bins=40, density=True) # n별 표본평균 분포
```

4) 결과.

→ n 이 커지며 왜도가 2.037→0.204로 줄어 종모양이 됐고, 표준편차는 2.091→0.198로 축소, 평균은 계속 2로 유지됐다.



5) 해석. 표본 크기가 증가하면서 분포의 모양과 퍼짐은 어떻게 달라지는가?

→ 세 가지가 동시에 일어난다 — 중심(평균)은 불변, 퍼짐(SD)은 $1/\sqrt{n}$ 로 축소(제곱근의 법칙), 모양(왜도)은 $1/\sqrt{n}$ 로 정규분포화(중심극한정리). 단, CLT는 모분산이 유한할 때만 성립한다(코시분포 등은 예외).

6) AI 응용. 중심극한정리는 AI 모델의 반복 평가와 어떤 관련이 있는가?

→ AI 모델의 반복 평가는 같은 모델을 시드·샘플링·데이터 순서 등을 바꿔 여러 번 평가하고 점수들을 모으는 것이다. 한 번의 점수만으로는 무작위성 때문에 진짜 성능을 판단할 수 없기 때문이다. 중심극한정리에 따라 반복 횟수가 늘수록 평균 점수의 분포는 정규분포에 가까워지고 그 분산은 $1/\sqrt{n}$ 로 줄어든다. 그 덕분에 모델 성능을 더 안정적으로 추정하고, 모델 간 성능 차이가 통계적으로 유의미한지 검정할 수 있다.

팀 토의 결과

- **제곱근의 법칙** — 처음엔 "데이터를 2배 늘리면 오차도 절반"이라고 본 의견이 있었으나, 분모가 $\sqrt{n}$ 이라 **4배를 늘려야 절반**이 된다는 점을 함께 확인했다. 정밀도를 높이는 비용이 제곱으로 커진다는 데 공감했다.
- **중심극한정리** — " $n \geq 30$ 이면 정규근사"라는 경험칙을 두고, 원분포의 치우침(왜도)이 클수록 더 큰 n 이 필요하다는 의견이 나왔다. 지수분포는 $n=30$ 에서도 약간의 비대칭이 남는 것을 그래프로 확인했다.
- 두 주제 모두 $\sqrt{n}$ 이 공통 핵심이며, AI 모델 평가에서 신뢰구간·반복 평가가 왜 필요한지로 연결된다는 데 의견이 모였다.

느낀점

측정된 점수를 그대로 믿기보다 **표본에서 얻은 추정치**로 보게 된 것이 가장 큰 배움이었다. AI 모델을 평가할 때 단일 seed 결과나 작은 테스트셋을 신뢰하는 것이 위험하다는 점을 체감했고, 앞으로 지표를 볼 때 신뢰구간과 표본 크기를 함께 확인해야겠다고 느꼈다. 통계 공식($\sigma/\sqrt{n}$)이 실제 시뮬레이션 값과 거의 정확히 맞아떨어지는 것을 눈으로 확인하면서 이론에 대한 신뢰도 커졌다.