


[Linear Regression] 부동산 가격 회귀분석 — 수행 보고서

2026-07-28 | 4기 광주 4반 박영서 | 데이터: UCI Real Estate Valuation (n=414, 대만 신덴구) · 종속변수 price(평균 37.98, 단위 면적당 가격) · OLS(statsmodels), train/test 8:2(seed=42) | 판단 근거(어떤 그래프·수치에서 찾았는지) 중심 정리

Task 1. Baseline 회귀분석 결과 해석


1-1. 분포와 왜도 — 이상치·비선형 예고



▲ 변수별 히스토그램(제목=skew). price-dist_to_mrt 오른쪽 꼬리

근거→판단 ① price skew +0.60 오른쪽 꼬리(고가 매물) → 잔차 정규성 위배 예상. ② dist_to_mrt skew +1.89 최대 → 로그변환 1순위 후보. ③ longitude skew -1.22이나 산점도상 대체로 증가 → 변환보다 공선성 문제.

1-2. 변수-price 관계 — 선형성 점검



▲ 변수 vs price 산점도+LOESS(빨강). 곡선이 직선 아니면 선형가정 의심


근거→판단 LOESS 모양에서: dist_to_mrt=급락 후 완만(감쇠형)→로그, house_age=U자(20년 최저)→제곱항. 나머지는 대체로 직선. 상관(강도): dist -0.67·n_conv +0.57·lat +0.55·lon +0.52·age -0.21. 강도는 상관, 모양은 LOESS로 분리 판단.

1-3. 회귀계수 해석

변수	계수	p	유의	상관	해석
transaction_date	+5.44	0.003	O	+0.09	거래시점 늦을수록 소폭↑
house_age	-0.27	<.001	O	-0.21	연식↑ 가격↓ (U자형이라 선형계수는 근사)
dist_to_mrt	-0.0048	<.001	O	-0.67	MRT 멀수록↓ (가장 강한 음의 관계)
n_convenience	+1.09	<.001	O	+0.57	편의점 1개↑ → 1.09↑
latitude	+229.0	<.001	O	+0.55	북쪽(도심)일수록↑
longitude	-29.5	0.599	X	+0.52	단순상관 큰데 모델선 비유의 → Task 3

적합도 $R^2=0.558$ ·Adj $R^2=0.550$ (분산 56% 설명). Train RMSE 9.12 > Test 7.31 역전은 과적합 아니라 고가 이상치(price 117.5)가 우연히 train에 포함된 탓(근거: 1-1 오른쪽 꼬리).


1-4. 잔차 진단



▲ (좌)잔차 vs 적합값 (우)Q-Q

- 등분산: BP p=0.209(>.05)+깁때기 없음 → 이분산 증거 약함.
- 정규성 위배: Q-Q 오른쪽 꼬리+잔차 skew 2.14·첨도 17.3·JB p≈0 → 이상치 탓.
- 공선성: 조건수 3.65e7(위치변수 중복). DW 1.92(자기상관 없음).

1-5. 잔차 vs 각 변수 — 비선형이 '어디에' 남았나



▲ 잔차 vs 각 변수. 0 주변 무작위가 아니면 그 변수 관계 미반영

근거→판단 house_age·dist_to_mrt의 잔차에 곡선/치우침 잔여(타 변수는 평평) = 두 변수 비선형이 baseline에 아직 안 잡힘 → Task 2 변환 대상 최종 확정.

Task 1 결론 — 분포·산점도·잔차 세 근거가 ① dist_to_mrt·house_age 비선형 ② 이상치로 인한 정규성 위배 ③ 위치변수 공선성을 일관되게 가리킴 → Task 2·3의 출발점.

Task 2. 모델 개선 — 비선형 변수의 선형화

2-1. 판단 근거를 어디서 찾았나 (3중 교차)

예시는 log_features=['house_age'] 였으나, 세 근거가 일관되게 다른 답을 가리켰다.


변수	① 산점도 모양(1-2)	② 잔차 잔여(1-5)	③ skew	③ quad_gain	③ log_gain	→ 처방
house_age	U자(비단조)	U자 잔여	0.38	0.157(최대)	0.066	제곱항(로그×)
dist_to_mrt	감쇠형	치우침 잔여	1.89(최대)	0.073	0.044	로그변환
n_convenience	거의 직선	평평	0.15	0.004	-0.019	변환 불필요

핵심 판단 — skew만 보면 안 된다. house_age는 skew(0.38) 작아도 quad_gain 0.157 최대·U자 → 제곱항이 맞다. 예시의 house_age 로그 변환도 개선은 되지않(Adj R² 0.550→0.579), 로그는 단조변환이라 U자 곡률을 다 담지 못해 **제곱항(0.586)**이 더 낫다. dist_to_mrt는 skew 1.89·감쇠형 → 로그. 같은 비선형도 U자나 감쇠나로 처방이 같린다.

2-2. 개선 후보 비교 — 근거대로 적용·검증

모델	처리	Adj R ²	Test RMSE	BP p	메모
Baseline	변환 없음	0.550	7.31	0.209	기준선
A	log1p(dist_to_mrt)만	0.627	6.78	0.131	감쇠형 로그화 효과 큼
B	house_age ² 만	0.586	6.90	0.315	U자 곡률 반영
C	log(dist)+house_age ²	0.645	6.55	0.221	두 처방 결합=최고

검증: 모델 C에서 house_age 1차(-0.879)·2차(+0.0161)이 모두 p<.001로 유의 → 그래프로만 봤던 U자형이 **통계로도 확인**. Adj R² 0.550→0.645, Test RMSE 7.31→6.55로 설명력·예측오차가 함께 개선됐다.



▲ 잔차 vs 적합값(개선 전 → 후). 후(우)에 큰 양(+) 잔차가 줄고 밴드가 균일해짐 = 1-5의 잔여 곡선 패턴 해소

Task 2 결론 — 변환 대상·방식을 감이 아니라 **세 근거(산점도·잔차·수치지표)의 일치**로 정했고, 적용 후 성능·잔차·계수 유의성으로 재검증했다.

Task 3. 유의하지 않은 변수 제거 — 유의성 vs 효과크기

3-1. p가 가장 큰 longitude(C에서 p=0.892, baseline 0.599로 일관 비유의) 제거. ※ 변수 수 7 = 원래 feature 6개 + 파생변수 house_age² 1개. longitude 제거 시 6개.

	변수 수	Adj R ²	Test RMSE	조건수(공선성)
모델 C (전체)	7 (feature 6 + house_age ²)	0.645	6.55	2.62e7
C - longitude	6	0.646	6.53	1.55e7

근거: 제거 후에도 Adj R²·Test RMSE가 손실 없이 미세 개선 + 조건수 2.62e7→1.55e7로 **1-4의 다중공선성이 실제 완화** → 제거 타당.

3-2. 유의성 vs 효과크기 — 판단 근거는 **수치의 모순**: longitude는 price와 **단순상관 +0.52**(효과 있어 보임)인데 **모델 p=0.6~0.9**(효과 없음). '위치' 정보가 위도·MRT거리와 겹쳐 고유 기여(부분효과)가 0에 가깝기 때문. **유의성**=다른 변수 통제 시 0과 구분 여부, **효과크기**=실질 기여 크기. longitude는 단독 효과는 있으나 모델 내 고유 효과크기가 작아 제거가 옳다.

추가 관찰 — 모델 C에서 n_convenience도 비유의(p=0.140)화됨(로그변환된 MRT거리가 '생활 편의' 정보 흡수). 다만 상관(+0.57)·해석이 좋아 **p값만으로 기계적 제거하지 않고** 효과크기·도메인 의미로 유지 판단도 가능.

종합 및 느낀점

단계	판단의 핵심 근거	Adj R ²	Test RMSE
Baseline	분포·산점도·잔차로 문제 진단(비선형·이상치·공선성)	0.550	7.31
Task 2	3근거 일치 → dist 로그 + house_age 제곱	0.645	6.55
Task 3	상관 vs p값·조건수 모순 해석 → longitude 제거	0.646	6.53

느낀점 — 하나의 지표가 아니라 **여러 근거의 일치**로 판단했다. skew 커도 U자면 제곱항(산점도·잔차·quad_gain 일치), 상관 높아도 모델선 비유의(상관 vs p값 모순). "왜 그렇게 판단했는가"를 그래프·수치로 되짚는 과정이 정답 값을 얻는 것보다 중요했다.